3.

(a1)

分类准确率: 72.00%

(a2)

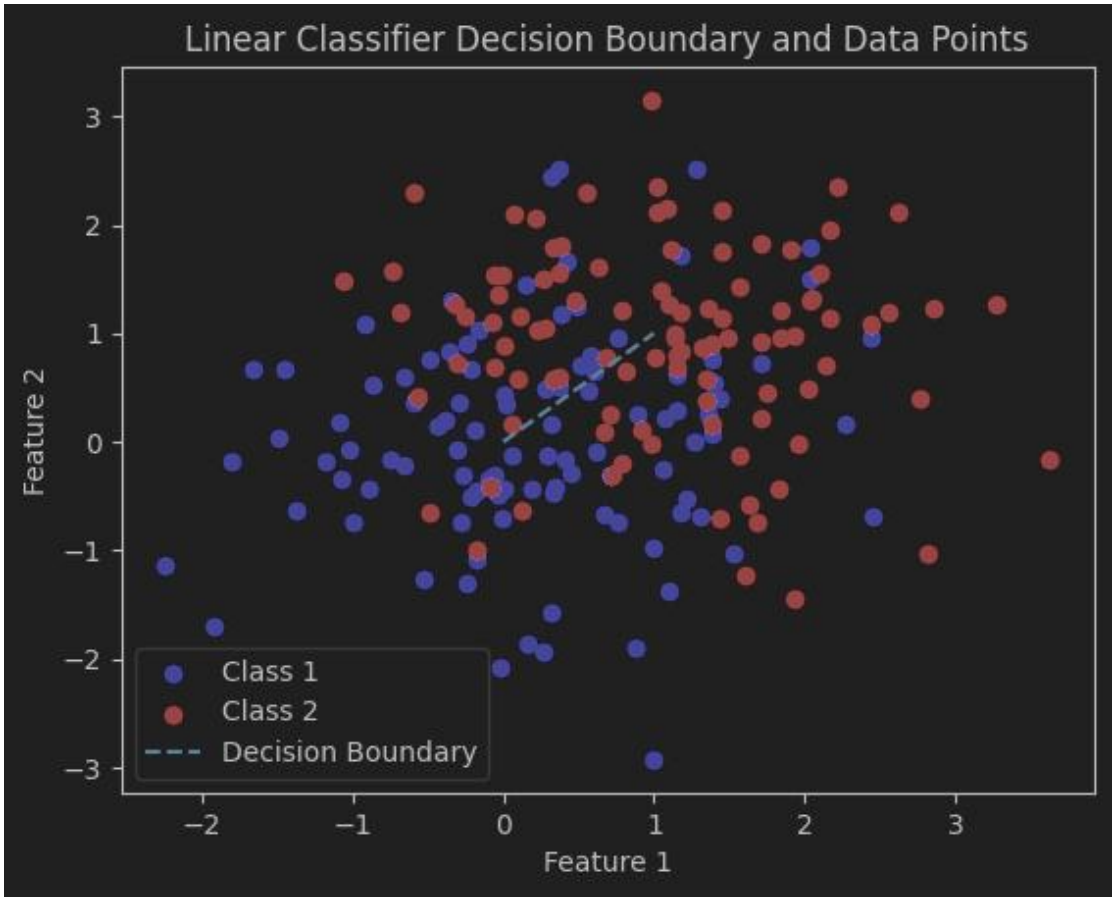

在问题 3(a1)中，我们使用的是最近邻分类器，它根据测试点到训练数据中所有点的距离来进行分类。具体来说，它将测试点分配给距离它最近的训练数据所属的类别。

分类器工作原理：

1. 计算距离：对于每个测试点，计算它与训练数据集中所有点的距离。可以使用各种距离度量，例如欧几里得距离或曼哈顿距离。
2. 确定最近邻：找到距离测试点最近的训练数据点。
3. 分类：将测试点分配给最近邻的类别。

影响准确性的因素：
数据分布：如果数据点在空间中彼此紧密相连，则最近邻分类器往往能很好地工作。如果数据点高度重叠或存在噪声，则该方法可能不那么准确。

特征空间维度：在高维空间中，距离度量变得不那么可靠，因为所有点之间的距离趋于相似。这会导致最近邻分类器变得难以区分不同的类别。
训练数据量：拥有更多的训练数据通常会导致更准确的分类，因为分类器可以更好地学习数据的模式。
距离度量：所选择的距离度量可能会影响分类器的性能。不同的距离度量可能适用于不同的数据类型。

在本例中，由于数据点被明确分为两个不同的集群，并且每个集群的均值相隔较远，因此最近邻分类器表现良好。 然而，如果两个集群之间的距离更近，或数据包含噪声，那么准确性可能会下降。

其他注意事项：
近邻分类器很容易受到离群值的影响。
为了提高准确性，可以使用 k-最近邻分类器，它考虑了测试点周围的 k 个最近邻，而不是仅考虑一个最近邻。
最近邻分类器通常用于非线性分类任务，因为它们不需要对数据进行任何假设。

(b1)

朴素贝叶斯分类器的平均准确率：78.27%

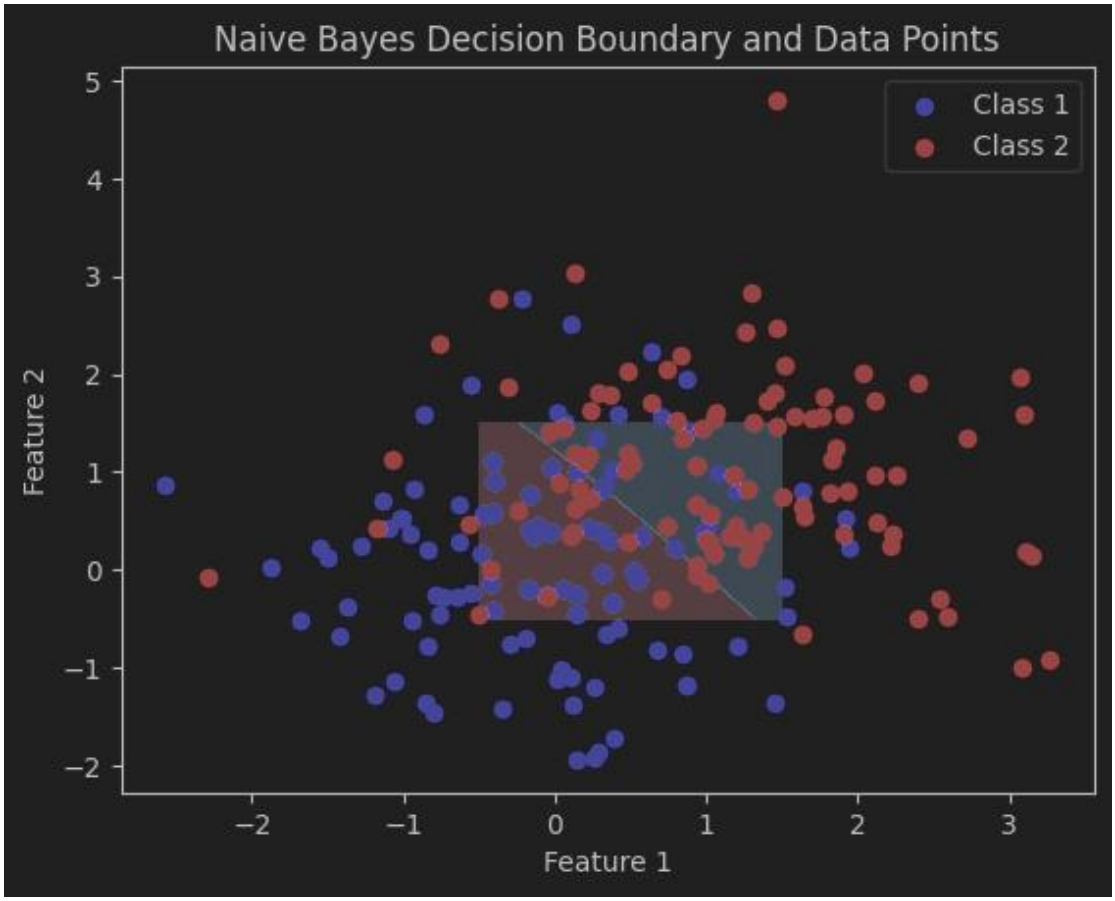

(b2)

朴素贝叶斯分类器的平均准确率：75.80%
LDA 分类器的平均准确率：72.22%

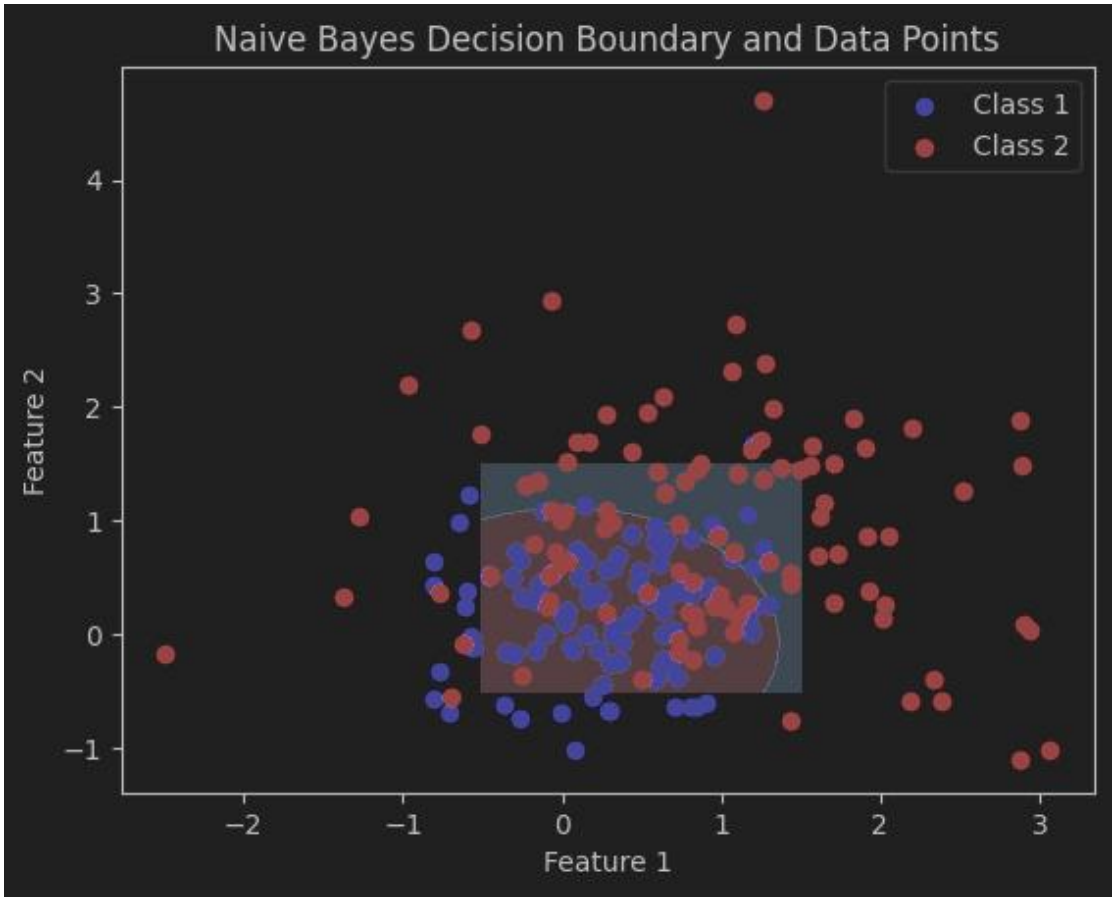

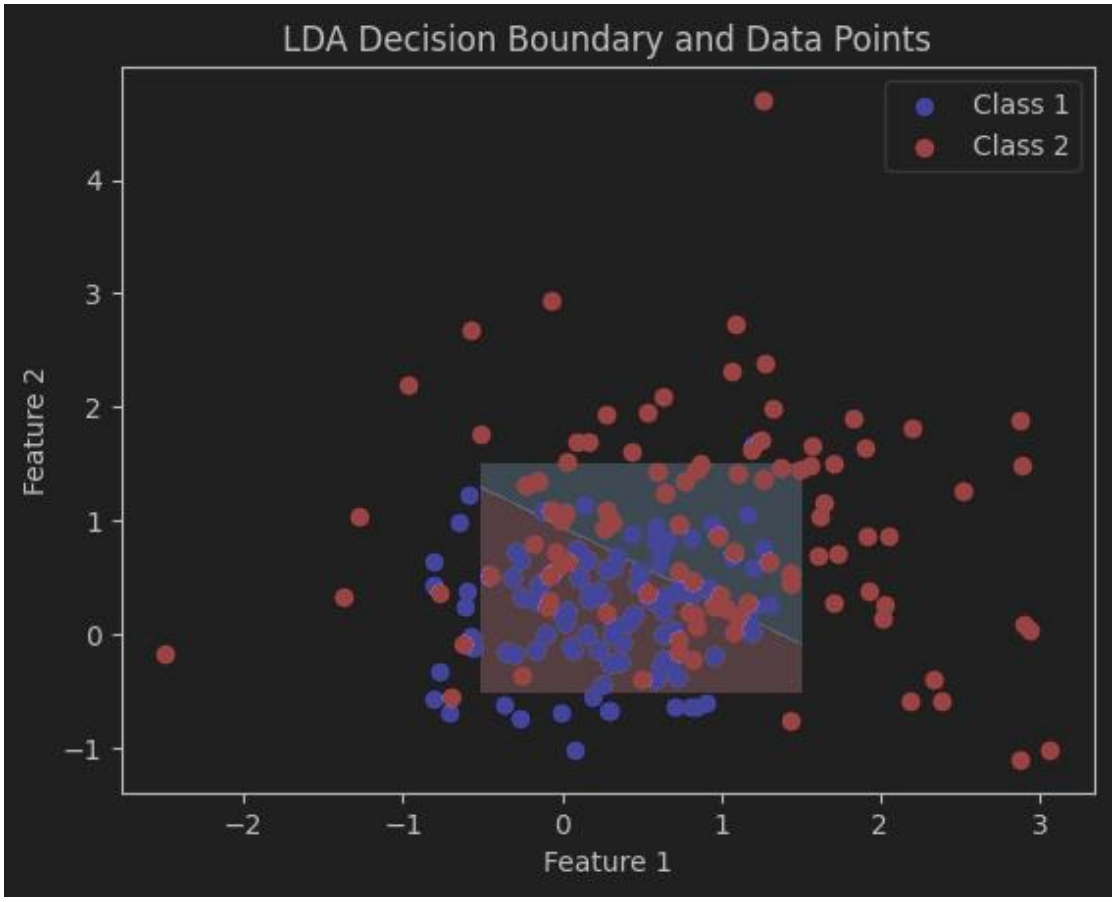

3(b1)中的朴素贝叶斯分类器
数据生成：两个簇的数据均值分别为 0.05 和 0.95，表示沿一条线的线性分离。
协方差：由于未指定，代码中隐含地使用了相同（恒定）的协方差。
分类器行为：朴素贝叶斯分类器通过计算每个类别的后验概率来工作。由于协方差是相同的，因此决策边界主要取决于类均值之间的距离。
决策边界：由于线性分离，决策边界将是一条垂直线，在两个均值之间。

3(b2) 中的朴素贝叶斯分类器
数据生成：两个簇的均值现在为 [0.25, 0.15] 和 [0.75, 0.85]，分别表示更复杂的二维分离。
协方差：两个簇的协方差矩阵不同：
簇 1：$\Sigma 1 = (0.35\ 0.1; 0.1\ 0.35)$，表示沿着对角线有更多扩展，这意味着数据在该方向上具有更高的方差。
簇 2：$\Sigma 2 = I(2)$，表示一个恒定的协方差矩阵，数据在所有方向上具有相等的方差。
分类器行为：由于协方差不同，决策边界将根据每个类别数据的方差和方向进行调整。
决策边界：决策边界将不再是一条直线，而是反映了每个类别的协方差结构的曲线。

主要区别：3(b1)和 3(b2)中的朴素贝叶斯分类器之间的主要区别在于协方差矩阵。在 3(b1) 中，使用相同的协方差矩阵，导致一个简单的线性决策边界。在 3(b2) 中，协方差矩阵不同，迫使决策边界适应每个类别数据的特定结构，导致一个非线性决策边界。

总结：朴素贝叶斯分类器对协方差矩阵的变化非常敏感。当协方差相同时，决策边界将是线性的。当协方差不同时，决策边界将更复杂，可以反映每个类别数据的特定结构。

(b3)

朴素贝叶斯分类器的平均准确率：78.37%
LDA 分类器的平均准确率：78.48%

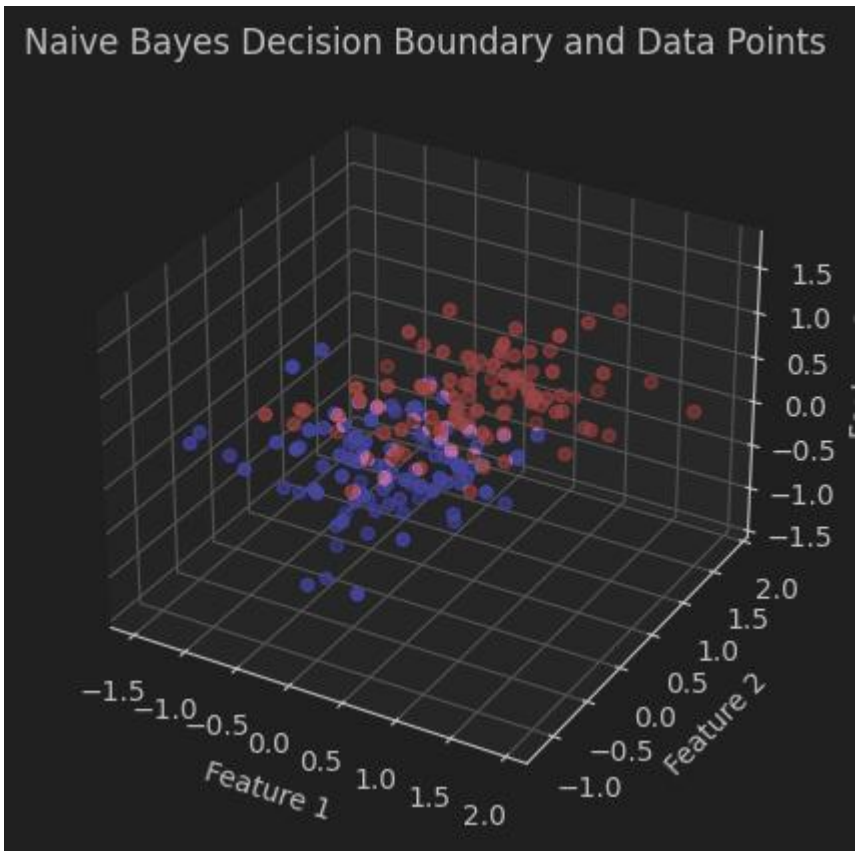

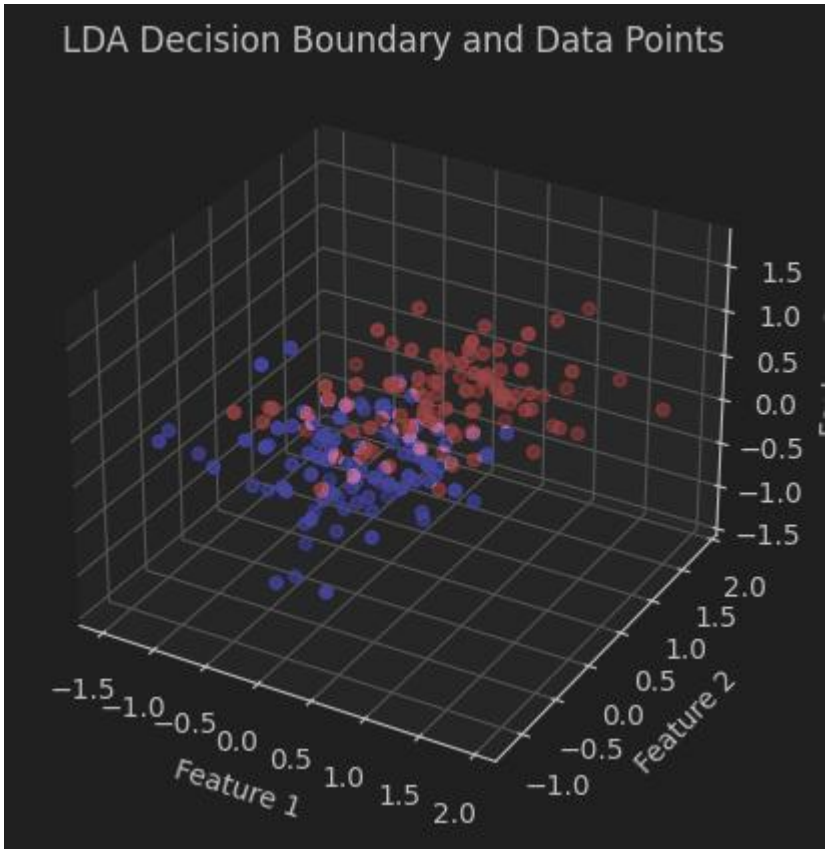

4(a&b)

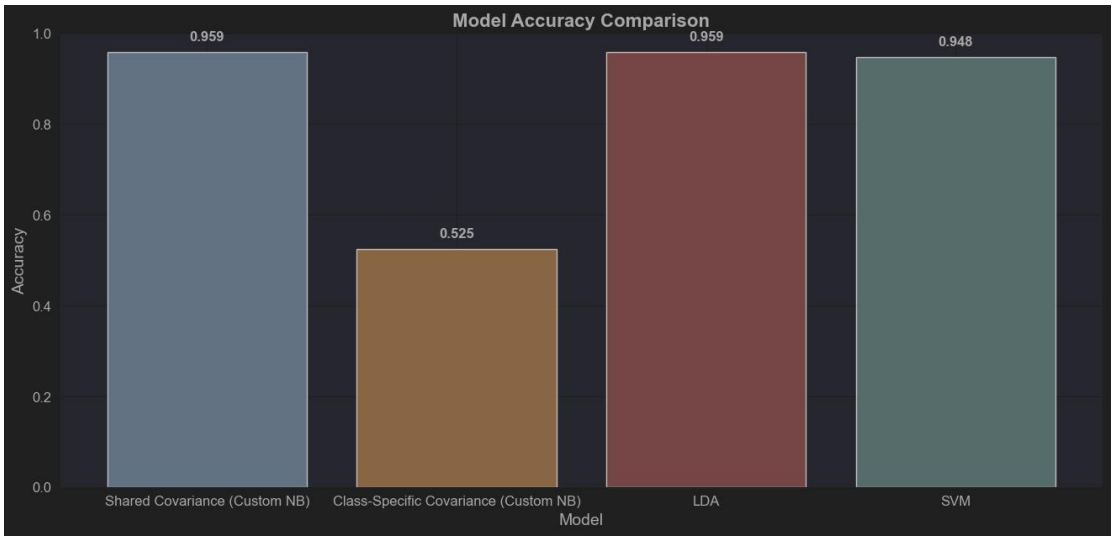

相似性：

都是线性分类器：LDA 和 SVM 都是线性分类器，这意味着它们都是通过寻找一个线性超平面来将数据点分成不同的类别。
基于特征空间：两种模型都基于特征空间，它们根据特征向量来对数据进行分类。
适用于高维数据：两种模型都适用于高维数据，可以处理大量特征。

差异：

目标函数： LDA 的目标函数是最大化类间方差并最小化类内方差，从而寻找一个能够最大程度区分不同类别的投影方向。SVM 的目标函数是最大化分类间隔，找到一个能够最大化数据点到分类边界的距离的超平面。
对异常值的敏感度： LDA 对异常值比较敏感，因为它们会影响类内方差的计算。SVM 对异常值不太敏感，因为它们主要关注分类间隔，而不是数据点的分布。
数据分布假设： LDA 假设数据服从多元正态分布，并且类协方差矩阵相同。SVM 没有对数据分布做出假设，因此在数据分布不符合多元正态分布的情况下，SVM 可能比 LDA 性能更优。
复杂度：LDA 的训练复杂度较低，但它的预测复杂度也较低。 SVM 的训练复杂度较高，尤其是在非线性核函数的情况下，但它的预测复杂度相对较低。

总结：

LDA 更适合于数据服从多元正态分布并且类协方差矩阵相同的情况，它在处理高维数据时效率更高。SVM 更适合于数据分布不符合多元正态分布或者类协方差矩阵不相同的情况，它在处理非线性数据时性能更优。

在实际应用中，选择使用哪种模型取决于数据的具体特性以及分类目标。如果数据分布比较简单，并且对异常值比较敏感，则可以选择 LDA。如果数据分布比较复杂，并且对异常值不太敏感，则可以选择 SVM。